

الجامعة السورية الخاصة

كلية هندسة الذكاء الاصطناعي

دبلجة الفيديوهات التعليمية إلى العربية

باستخدام تقنيات الذكاء الاصطناعي

AI-Powered Dubbing of Educational Videos into Arabic

تقرير مشروع التخرج

إعداد الطالبين

حمزة السمان | رغد عبد الرحمن

بإشراف

د. ماجدة الكبور | م. وسام السحلي

تشرين الأول — 2026

الإهداء والشكر

نتقدم بخالص الشكر والتقدير إلى المشرفين على المشروع لما يقدمانه من توجيهات وملاحظات علمية خلال مراحل العمل، وإلى أساتذة كلية هندسة الذكاء الاصطناعي على ما قدموه من معرفة أسهمت في بناء أساسنا العلمي.

كما نعبر عن تقديرنا لعائلاتنا وزملائنا ولكل من أسهم في تيسير العمل والدراسة.

الملخص

يهدف مشروع «دبلجة الفيديوهات التعليمية إلى العربية باستخدام تقنيات الذكاء الاصطناعي» إلى بناء مسار آلي ينقل المحتوى المنطوق من الإنجليزية إلى العربية، مع الحفاظ على دقة المعنى والمصطلحات التعليمية وضبط مدة الكلام العربي لتتوافق مع زمن الفيديو. تتطلب المهمة تكامل معالجة الصوت والتعرف على الكلام ومحاذاة الكلمات والترجمة السياقية وتوليد الكلام ومزامنة الصوت والصورة، بالإضافة إلى تقييم منضبط لكل مرحلة.

أُنجز في مرحلة تخرج 1 تدريب نموذج DualStreamResUNet لفصل الصوت عن الضجيج، إلى جانب تنفيذ مراحل برمجية لتفريغ الكلام وتوقيته وترجمته وتوليد الصوت العربي وإعادة المزج. تُظهر مخرجات التقييم المحفوظة للنموذج متوسط PESQ مقداره 2.6918 وSTOI مقداره 0.9385 وDNSMOS مقداره 3.0857 وSI-SDR مقداره 20.2707 ديسيبل. وسُجل WER مقداره 0.0219 بعد فصل الضجيج مقابل 0.0241 للصوت المشوّش. لكن هذه نتائج جزئية على عينة محدودة من VoiceBank-DEMAND؛ إذ تحد الدالة المقاييس الصوتية إلى أول 100 عينة، ويُحسب WER لأول 30 عينة بمرجع آلي من Whisper على الصوت النظيف، لذلك لا تمثل تقييمًا كاملًا للدبلجة التعليمية.

تقترح المرحلة التالية إعداد مجموعة فيديوهات تعليمية مرخصة ذات مراجع مستقلة، ثم مقارنة ترجمة مباشرة بترجمة مراعية للسياق والمصطلحات، ومقارنة ضبط مدة الكلام وجودة الصوت عبر تجارب مضبوطة. لا توجد بعد نتائج معتمدة للتقييم المتكامل من الفيديو إلى الفيديو أو لإثبات تفوق المنظومة على أنظمة بديلة.

Abstract

This graduation project investigates an AI-assisted workflow for dubbing educational videos from English into Arabic while preserving scientific meaning and terminology and aligning the resulting speech with the source video. The planned system combines speech–noise separation, time-aligned English speech transcription, context-aware machine translation, Arabic text-to-speech, duration control, conditional lip synchronization, and audio-video mixing.

During Graduation Project I, a DualStreamResUNet speech–noise separation model was trained and evaluated, alongside implementation work on transcription, translation, speech synthesis, and video output. Saved evaluation outputs report mean PESQ 2.6918, STOI 0.9385, DNSMOS 3.0857, SI-SDR 20.2707 dB, and WER 0.0219 for the separated speech compared with 0.0241 for noisy audio. These metrics were computed on restricted subsets of VoiceBank-DEMAND, and the WER reference was generated automatically using Whisper rather than independently verified human transcripts.

Further work requires a rights-cleared English-Arabic educational-video evaluation set, controlled baselines, terminology-specific translation assessment, and measurement of speech timing and final video quality. The complete end-to-end system has not yet been established as experimentally superior.

فهرس المحتويات

الإهداء والشكر 2
الملخص 3
Abstract 4
فهرس المحتويات 5
قائمة الجداول 7
قائمة الأشكال 7
قائمة الاختصارات 8
الفصل الأول — المقدمة 9
1.1 مقدمة عامة 9
1.2 صياغة المشكلة البحثية 9
1.3 أهداف المشروع 9
1.4 إسهام البحث المتوقع 9
1.5 المستفيدون وحدود النطاق 9
1.6 تنظيم التقرير 10
الفصل الثاني — الدراسة النظرية 11
2.1 الصوت التعليمي ومصادر التشويش 11
2.2 الشبكات العصبية لفصل الصوت عن الضجيج 11
2.3 التعرف الآلي على الكلام ومحاذاة الكلمات 11
2.4 الترجمة العربية في السياق العلمي 11
2.5 توليد الكلام العربي والتشكيل 11
2.6 مواءمة مدة الكلام والمزامنة 11
2.7 المقاييس ومحدودية كل مقياس 12
الفصل الثالث — الدراسات السابقة 13
3.1 منهج اختيار الأدبيات 13
3.2 ASCAT: Arabic Scientific Benchmark for Advanced Translation Evaluation (2026) 13
3.3 QUANTA: A Fine-Grained Dataset and Benchmark for Arabic MT Error Analysis (2026) 13
3.4 SawtArabi: A Benchmark Corpus for Arabic TTS (2025) 14
3.5 End-to-End Multilingual Automatic Dubbing via Duration-based Translation (2025) 14
3.6 دراسات مساندة لا تُعد بديلًا عن المقارنة 14
3.7 X-Dubbing (2026): اتجاه حديث في الدبلجة المتكاملة 14

3.8 مقارنة نقدية 15
3.9 الفجوة البحثية المحتملة 15
الفصل الرابع — منهجية البحث والعمل المنجَز 16
4.1 مصادر الأدلة البرمجية 16
4.2 نموذج فصل الصوت عن الضجيج المنجَز في تخرج 1 16
4.3 بيانات التقييم المتاحة ونطاقها 16
4.4 المعمارية المقترحة للمنظومة 17
4.5 منهجية الترجمة ذات المراحل الست 18
4.5.1 حزمة المقطع 18
4.5.2 فهم السياق 18
4.5.3 ترجمة دقيقة أولية 18
4.5.4 تكييف للإلقاء 18
4.5.5 مراعاة طول الجملة 18
4.5.6 فحص جودة آلي 18
4.6 إعداد مجموعة بيانات مستقلة للبحث 18
4.7 خطة المقارنات واختبار أثر التحسينات 19
الفصل الخامس — النتائج المتاحة ومناقشتها 20
5.1 نتائج نموذج فصل الصوت عن الضجيج 20
5.2 قراءة الفرق بين WER قبل المعالجة وبعدها 20
5.3 ما الذي أثبتته التجارب وما الذي لم تثبته؟ 20
5.4 محدوديات النتائج الحالية 20
5.5 مناقشة أولية 21
الفصل السادس — الاستنتاجات والعمل المستقبلي 22
6.1 ما تحقق حتى الآن 22
6.2 توصيات استكمال الدراسة 22
6.3 المخاطر وخيارات التخفيف 22
6.4 الخاتمة 22
المراجع 23
مصادر داخلية غير منشورة ..... **Error! Bookmark not defined.**
الملحق أ — قائمة الاستكمال قبل الاعتماد ..... **Error! Bookmark not defined.**
الملحق ب — سجل القرارات المنهجية ..... **Error! Bookmark not defined.**

الملحق ج — صيغ المقاييس الأساسية ..... **Error! Bookmark not defined.**

WER ..... **Error! Bookmark not defined.**

SI-SDRi ..... **Error! Bookmark not defined.**

الخطأ النسبي في المدة ..... **Error! Bookmark not defined.**

RTF ..... **Error! Bookmark not defined.**

قائمة الجداول

جدول 1: مقاييس تقييم مكونات الدبلجة

جدول 2: مقارنة الدراسات المرجعية المختارة

جدول 3: تفاصيل كل دراسة من حيث البيانات والتقنيات والنتائج

جدول 4: إعدادات تدريب نموذج فصل الصوت عن الضجيج

جدول 5: وصف مجموعة الاختبار المستخدمة حاليًا

جدول 6: مكونات المنظومة وحالة إنجازها

جدول 7: خطة اختبار التحسينات والمقارنات المقترحة

جدول 8: نتائج نموذج فصل الصوت عن الضجيج المسجّلة

جدول 9: المخاطر والتخفيف

جدول 10: العناصر المطلوبة لاستكمال التقرير

قائمة الأشكال

الشكل 1: مراحل المنظومة المستهدفة من فيديو إنجليزي إلى عربي

الشكل 2: مسار الترجمة والتوليد

الشكل 3: تصميم التجارب المنضبطة B0 وE1 وE2 وE3

الشكل 4: مقارنة WER بين الصوت المشوش والمحسن

قائمة الاختصارات

الاختصار	التسمية	الاستخدام في المشروع
ASR	Automatic Speech Recognition	تحويل الصوت الإنجليزي إلى نص
TTS	Text-to-Speech	توليد الكلام العربي
WER	Word Error Rate	نسبة أخطاء التفريغ
PESQ	Perceptual Evaluation of Speech Quality	الجودة الإدراكية مع مرجع
STOI	Short-Time Objective Intelligibility	قابلية فهم الكلام
DNSMOS	Deep Noise Suppression Mean Opinion Score	تقدير آلي لجودة الكلام
SI-SDR	Scale-Invariant SDR	جودة فصل الإشارة مقارنة بمرجع
SI-SDRi	SI-SDR improvement	التحسن مقارنة بالمزيج
COMET	Crosslingual Optimized Metric for Evaluation of Translation	مقياس جودة ترجمة آلي
RTF	Real-Time Factor	سرعة المعالجة بالنسبة لمدة التسجيل
EDA	Exploratory Data Analysis	وصف وتحليل البيانات
Ablation	Ablation study	عزل أثر كل مكون

الفصل الأول — المقدمة

1.1 مقدمة عامة

أتاحت المنصات الرقمية انتشارًا واسعًا للمحاضرات والدروس والفيديوهات التوضيحية باللغة الإنجليزية. غير أن الحاجز اللغوي قد يحد من الاستفادة من هذا المحتوى لدى فئات من المتعلمين العرب، خصوصًا عندما يعتمد الشرح على مصطلحات تخصصية أو على تتابع كلام سريع متصل بإشارات ومشاهد ضمن الفيديو. إن تحويل هذا المحتوى إلى العربية لا يقتصر على استبدال كلمات بأخرى، بل يتطلب نقل العلاقات العلمية والمحافظة على المصطلح والتسلسل والإيقاع الزمني.

تختلف الدبلجة عن الترجمة النصية العادية لأنها تُنتج كلامًا جديدًا ينبغي أن يقع في نافذة زمنية محددة وأن يحافظ على مفهوم المحاضر ووضوح التعبير. وتصبح المشكلة أشد تعقيدًا حين توجد موسيقى خلفية أو ضجيج، أو حين يستعمل الشرح ألفاظًا متخصصة ليس لها مقابل مباشر واحد. ولهذا، يتطلب المسار الناجح تنسيق المكونات الصوتية واللغوية والمرئية وتقييمها على بيانات مناسبة بدل الحكم على تشغيل النموذج فقط.

1.2 صياغة المشكلة البحثية

تتمثل المشكلة الرئيسة في تحقيق دبلجة عربية للفيديوهات التعليمية تجمع بين أمانة المعنى العلمي ودقة المصطلحات وطبيعية الصوت والتزامن المقبول مع زمن الفيديو. ويمكن أن تنتقل أخطاء التفريغ الإنجليزي إلى الترجمة العربية، وقد تؤدي صياغة عربية صحيحة دلاليًا إلى صوت أطول من الزمن المتاح، ما يفرض مقايضة بين الاختصار والدقة. ولا تضمن جودة مكون منفرد، كفصل الضجيج، جودة المنظومة النهائية بالضرورة.

السؤال البحثي المقترح: كيف يؤثر استخدام سياق الدرس والمصطلحات العلمية، إلى جانب الترجمة المراعية لمدة الكلام، في دقة الدبلجة التعليمية الإنجليزية–العربية ومواءمتها الزمنية مقارنة بخط معالجة مرجعي ثابت؟

1.3 أهداف المشروع

- إنشاء مسار عملي ينتقل من فيديو تعليمي إنجليزي إلى نسخة عربية مدبلجة.
- الاستفادة من نموذج فصل الصوت عن الضجيج الذي دُرّب في تخرج 1 لاستخراج كلام المتحدث من التسجيل المشوّش.
- تطوير مسار ترجمة عربية يراعي السياق والمصطلحات والأرقام والروابط العلمية.
- توليد كلام عربي واضح وضبط مدته مع توقيت الفيديو مع المحافظة على المعنى.
- تقييم كل مكون ومقارنة التحسينات على بيانات اختبار ثابتة بمقاييس مناسبة ومتعددة.

1.4 إسهام البحث المتوقع

الإسهام العلمي المحتمل هو دراسة أثر التكييف المراعي للمصطلحات والمدة على مجموعة من الفيديوهات التعليمية الإنجليزية–العربية باستخدام Baselines وتجارب Ablation، وليس مجرد تجميع مكونات متاحة. ويجب إثبات هذا الإسهام بالتقييم قبل وصفه بالابتكار المحقق أو الادعاء بأن المنظومة تتفوق على حلول سابقة. كما أن نتائج النموذج الصوتي الموجود بالفعل تمثل دليلًا جزئيًا منفصلًا عن نتائج الدبلجة الكاملة.

1.5 المستفيدون وحدود النطاق

قد يستفيد المتعلم من وصول المحتوى بلغته، والمحاضر من إتاحة درسه لجمهور عربي أكبر، وجهات الإنتاج من تسهيل بعض مراحل الإعداد. هذه فوائد مستهدفة لم تُقَس بعد من خلال دراسة مستخدمين أو تحليل مالي. ينحصر النطاق الحالي في فيديوهات تعليمية يفترض فيها محاضر رئيسي واحد، ولا يتضمن تطوير نظام لفصل متحدثين متداخلين. كما تُجرى مزامنة الشفاه فقط عند وجود وجه قابل للتقييم.

1.6 تنظيم التقرير

يتناول الفصل الثاني الأسس النظرية، ويعرض الثالث الأدبيات ذات الصلة، بينما يصف الرابع العمل السابق والمنظومة المقترحة وخطة المقارنة. ويورد الخامس النتائج الصوتية الموثقة وحدود الاستدلال، ويقدم السادس الخلاصة والخطوات اللازمة لاستكمال الدراسة.

الفصل الثاني — الدراسة النظرية

2.1 الصوت التعليمي ومصادر التشويش

يتألف تسجيل المحاضرة من الكلام المستهدف، وقد تصاحبه أصوات المكيف والاحتكاك والقاعة والموسيقى الخلفية. يركز النموذج الذي درّبناه على فصل الكلام عن الضجيج (Speech–Noise Separation) واستخراج إشارة الكلام من التسجيل المشوّش. وهذه المهمة لا تعني بالضرورة فصل الموسيقى أو جميع المؤثرات الصوتية؛ إذ يتطلب ذلك بيانات وتقييمًا ملائمين لمصادر الصوت المختلفة.

2.2 الشبكات العصبية لفصل الصوت عن الضجيج

يمكن استخدام الشبكات العصبية لتقدير إشارة الكلام من تمثيل زمني-ترددي مثل STFT، أو من عينات الموجة مباشرة. بُني نموذج DualStreamResUNet في مشروعنا بمسارين لتمثيل الكلام والضجيج، وتساعد الاتصالات المتبقية والبنى متعددة المقاييس على استخراج خصائص ترددات مختلفة.

تُحوَّل الإشارة إلى تمثيل طيفي يضم مركبات زمنية وترددية؛ ثم تقدّر الشبكة مكوّن الكلام في وجود الضجيج وتعيد بناء إشارة الكلام المفصولة. تعتمد جودة الفصل على بنية النموذج والبيانات ودالة الخسارة وطريقة إعادة بناء الإشارة.

2.3 التعرف الآلي على الكلام ومحاذاة الكلمات

يحوّل ASR إشارة الحديث الإنجليزي إلى كلمات، لكن التوقيت الذي يخرجه النموذج قد يكون غير دقيق بما يكفي للدبلجة على مستوى المقاطع. يعالج WhisperX هذا الأمر باستخدام كشف النشاط الصوتي ومحاذاة قسرية للكلمات [R4]. ومن الضروري الاحتفاظ بمعرف الوحدة الأصلي وأزمنة البداية والنهاية وتوقيت الكلمات ليظل ربط النص بالصوت والفيديو ممكنًا بعد الترجمة.

2.4 الترجمة العربية في السياق العلمي

لا يكفي التطابق القاموسي عند ترجمة الشرح العلمي؛ فقد يختلف معنى كلمة مثل precision عن accuracy، ويتطلب الاختيار الصحيح معرفة المجال. وتحصل المشكلة نفسها مع كلمة script التي قد تعني شيفرة برمجية أو نصًا للحوار. يستلزم ذلك ربط الترجمة بسياق المقطع والمصطلحات المتكررة في الدرس، والحفاظ على النفي والأرقام والعلاقات الكمية. تقترح الدراسة الاستفادة من قائمة مصطلحات ثابتة وآلية فحص لاحق، مع الاعتراف بإمكان وقوع أخطاء رغم الفحص الآلي.

2.5 توليد الكلام العربي والتشكيل

تواجه TTS العربية تحديات اختيار النطق والتشكيل ومعالجة الكلمات الأجنبية والاختصارات والأرقام. تقدم دراسة SawtArabi بيانات TTS متعددة الأنماط وتسلط الضوء على التشكيل والتقسيم الصوتي للغة العربية [R7]. وتحتاج المحاضرات التقنية إلى نطق طبيعي للمصطلحات المعربة والأسماء والرموز وتوقيت يسمح للمتعلم بمتابعة الرسوم المعروضة.

2.6 مواءمة مدة الكلام والمزامنة

قد يكون زمن نطق ترجمة عربية أطول من الجملة الإنجليزية حتى لو كانت الترجمة دقيقة. لهذا يُقترح تقدير مدة النص العربي أوليًا، ثم حساب مدة TTS الفعلية بعد التوليد، وإعادة الصياغة عند الضرورة دون إسقاط فكرة علمية. تشرح دراسة DT 2025 طريقة لتحسين التوافق الزمني عبر توقع عدد الفونيمات وضبط طول الترجمة، لكن نتائجها ليست اختبارًا مباشرًا للزوج الإنجليزي–العربي [R3]. أما Lip Sync فهو مشكلة مختلفة تتعلق بتوافق الصوت مع حركة الشفاه عند وجود وجه ظاهر.

2.7

المقاييس ومحدودية كل مقياس

المهمة	المقياس	التفسير وشروط الاستخدام
فصل الصوت عن الضجيج	PESQ	جودة إدراكية مقارنة بمرجع نظيف؛ أعلى أفضل ضمن مجال المقياس.
قابلية فهم الكلام	STOI	درجة تفهم الكلام بمقارنة مرجعية؛ أعلى أفضل.
جودة بلا مرجع	DNSMOS	تقدير آلي لجودة الكلام، لا يساوي حكم المستمع البشري.
فصل الإشارة	SI-SDR / SI-SDRi	SI-SDR جودة مقابل مرجع؛ SI-SDRi مقدار التحسن مقارنة بالصوت الداخل.
تفريغ الكلام	WER	مجموع الاستبدالات والحذف والإضافة على عدد كلمات المرجع؛ أقل أفضل.
الترجمة	chrF++ / COMET	مؤشرات جودة آلية، مع اختبار مستقل للمصطلحات والمعنى.
مدة المقاطع	Duration Error	الفرق بين الزمن المستهدف والزمن الفعلي للصوت المولّد.
توافق الشفاه	LSE-D / LSE-C	تُطبّق عند وجود وجه مناسب فقط؛ لكل منها اتجاه تفسير.
النظام الكامل	RTF / معدل الإكمال	قياس زمن معالجة الفيديو ونسبة إخراج ملفات قابلة للتشغيل.

الفصل الثالث — الدراسات السابقة

3.1 منهج اختيار الأدبيات

تستهدف مراجعتنا أبحاثًا ترتبط على نحو مباشر بمحاور المشروع: الترجمة العلمية الإنجليزية–العربية، تشخيص أخطاء الترجمة العربية، توليد الكلام العربي، مواءمة زمن الدبلجة، والأنظمة المتكاملة الحديثة. ولا تُقارن القيم الرقمية بين الدراسات المختلفة من دون تثبيت البيانات والمهمة والمقياس؛ فـBLEU لقياس تشابه ترجمة، وMacro-F1 لتصنيف أخطاء، وSpeech Overlap لتقدير جانب زمني، وهي ليست مؤشرات لمهمة واحدة.

3.2 ASCAT: Arabic Scientific Benchmark for Advanced Translation Evaluation (2026)

الحقل	التفاصيل
رقم الدراسة	R5
اسم الدراسة	ASCAT: Arabic Scientific Benchmark for Advanced Translation Evaluation
السنة	2026
البيانات	500 ملخص علمي إنجليزي–عربي من خمسة مجالات، مع مراجعة خبراء.
التقنيات	إنشاء مجموعة ترجمة موازية عبر محركات متعددة وتحرير تخصصي ثم اختبار نماذج لغوية.
أهم النتائج	بلغ BLEU لدى GPT-4o-mini قيمة 37.07 على بيانات المجموعة (نتيجة منشورة للباحثين).
معايير التقييم	BLEU

صلة الدراسة وحدود الاستفادة: تستهدف ملخصات مكتوبة، ولا تمثل مجموعة فيديوهات تعليمية أو تقييمًا لنموذجنا.

3.3 QUANTA: A Fine-Grained Dataset and Benchmark for Arabic MT Error Analysis (2026)

الحقل	التفاصيل
رقم الدراسة	R6
اسم الدراسة	QUANTA: A Fine-Grained Dataset and Benchmark for Arabic MT Error Analysis
السنة	2026
البيانات	9,032 مثالًا لتشخيص أخطاء EN→AR، منها بيانات حقيقية ومولّدة ومجموعة ذهبية محجوزة.
التقنيات	تصنيف Mizan من 23 فئة ومصنف Raqeeb مبني على AraBERT-v2.
أهم النتائج	Macro-F1 = 0.614 ± 0.017 في تصنيف الأخطاء؛ ليس مقياسًا لجودة مترجم عربي.
معايير التقييم	Macro-F1

صلة الدراسة وحدود الاستفادة: تفيد في تشخيص الأخطاء، لكنها ليست محرك ترجمة أو TTS ولا تختبر الدبلجة.

3.4 SawtArabi: A Benchmark Corpus for Arabic TTS (2025)

الحقل	التفاصيل
رقم الدراسة	R7
اسم الدراسة	SawtArabi: A Benchmark Corpus for Arabic TTS
السنة	2025
البيانات	نحو أربع ساعات من التسجيلات: فصحى، مصرية، إنجليزية وتحويل بين اللغات.
التقنيات	تحسين المعالجة الصوتية والتشكيل باستخدام espeak-ng معدّل وخطوط TTS مرجعية.
أهم النتائج	تؤكد الدراسة أهمية التشكيل وفائدة المعالجة الصوتية المخصصة للعربية، مع تقييم استماع بشري.
معايير التقييم	تقييمات استماع ذاتية منشورة

صلة الدراسة وحدود الاستفادة: تستهدف توليد الكلام لا نقل المعنى العلمي أو ضبط وقت الفيديو النهائي.

3.5 End-to-End Multilingual Automatic Dubbing via Duration-based Translation (2025)

الحقل	التفاصيل
رقم الدراسة	R3
اسم الدراسة	End-to-End Multilingual Automatic Dubbing via Duration-based Translation
السنة	2025
البيانات	أزواج لغات تتضمن الإنجليزية والإسبانية والكورية؛ ليست مجموعة EN→AR تعليمية.
التقنيات	ترجمة مقيدة بالمدة عبر توقع عدد الفونيمات وضبط طول النص تكراريًا.
أهم النتائج	تحسن نسبي يصل إلى 24% في Speech Overlap مقارنة بترجمة بلا قيد طول، وفق تجارب الباحثين.
معايير التقييم	Speech Overlap وCOMET

صلة الدراسة وحدود الاستفادة: يمكن الاستفادة من ضبط المدة منهجيًا؛ لا تنقل نتيجتها العددية إلى العربية دون اختبار.

3.6 دراسات مساندة لا تُعد بديلًا عن المقارنة

تقدم WhisperX مكونًا مهمًا للتفريغ ومحاذاة الكلمات [R4]، بينما يدعم COMET تقييم جودة الترجمات آليًا [R8]. وتُظهر Locate-and-Focus (ACL 2025) أهمية المصطلحات في ترجمة الكلام، لكن بياناتها المنشورة لا تمثل اختبارًا مباشرًا من الإنجليزية إلى العربية [R2]. هذه الأدوات والأبحاث تساعد في تصميم النظام، إلا أن وجودها ضمن خط معالجة واحد لا يكفي وحده لإثبات مساهمة علمية جديدة.

3.7 X-Dubbing (2026): اتجاه حديث في الدبلجة المتكاملة

طرحت X-Dubbing في 23 أكتوبر 2026 إطارًا يجمع مترجمًا مراعيًا للقيود الزمنية مع مولّد صوت يستفيد من المعلومات المرئية، وبآلية تغذية راجعة بين النص والصوت [R9]. وتذكر أنها لا تحتاج إلى بيانات دبلجة ثنائية اللغة متقابلة في تدريب الجزأين، اعتمادًا على بيانات كلام–نص وبيانات سمعية بصرية أحادية اللغة. إن هذا العمل مهم للتقرير؛ فهو يبيّن أن فكرة النظام المتكامل موضوع بحث

قائم بالفعل، ويحثنا على تحديد مساهمتنا بدقة. وتظل الورقة نسخة أولية على arXiv، ولا نملك نتائج موثقة لتطبيقها على العربية في مشروعنا.

3.8 مقارنة نقدية

الدراسة	الجانب الذي تقدمه	ماذا لا تثبته لمشروعنا
ASCAT	معيار نصي علمي للإنجليزية–العربية	لا تقدم صوت دبلجة أو التزامن.
QUANTA	توصيف وتصنيف أخطاء الترجمة العربية	لا تنتج ترجمة ولا تختبر الفيديو.
SawtArabi	بيانات TTS وتشكيل ونطق عربي	لا تقيس جودة EN→AR داخل نظام دبلجة كامل.
DT	تحسين التوافق الزمني في الدبلجة	لا تقدم نتائج على محاضرات إنجليزية–عربية.
X-Dubbing	تكامل ترجمة وتوليد صوت مراعيين للفيديو	لا يثبت تفوق نهجنا أو أصالته بلا مقارنة.

3.9 الفجوة البحثية المحتملة

تقترح الأدبيات فرضية مفيدة: من الضروري قياس أثر الترجمة السياقية المدعومة بالمصطلحات وضبط المدة معًا على محتوى تعليمي إنجليزي–عربي، مع تجارب عزل دقيقة تحفظ البيانات والنسخ ومراجع الاختبار. لا يمكن الجزم بأن هذه الفجوة لم تُدرس عالميًا إلا بعد مسح أوسع للأعمال الحديثة والأنظمة المتكاملة، ومنها X-Dubbing.

الفصل الرابع — منهجية البحث والعمل المنجَز

4.1 مصادر الأدلة البرمجية

يعتمد وصف التنفيذ على دفترَي المشروع الأصليين: speech_noise_separation_Model.ipynb المخصص لتدريب وتقييم نموذج فصل الصوت عن الضجيج، وArabic_Dubbing_System.ipynb الذي يوثّق تنفيذ بعض مراحل الدبلجة. لا يُعد وجود شفرة أو إخراج مسجّل في دفتر برهانًا كافيًا على نجاح جميع المراحل بصورة مستقلة؛ لذلك تُفصل حالة كل مكوّن عن الخطة المستقبلية.

4.2 نموذج فصل الصوت عن الضجيج المنجَز في تخرج 1

دُرّب نموذج DualStreamResUNet على تسجيلات نظيفة ومشوّشة من مجموعة VoiceBank-DEMAND بدقة عينات 16 kHz. يتضمن إعداد التدريب استخدام مقاطع طولها ثانيتان، وتمثيل STFT وطيفيًا، ودفعات حجم 16، وخمسين حقبة تدريب مضبوطة في الدفتر، مع AdamW. يتضمن الدفتر كذلك تقسيمًا للتحقق بحسب هوية المتحدث، لكن ينبغي التأكد من تطبيق كل قواعد عدم التسرب في النسخة المستخدمة عند إعداد النتائج.

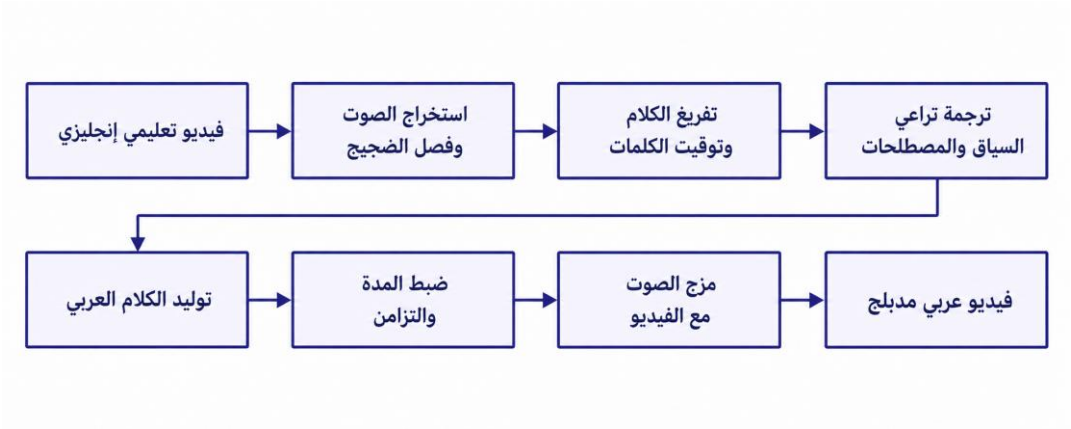
المتغير	القيمة الموجودة في دفتر التدريب
البيانات	VoiceBank-DEMAND — ملفات clean/noisy
نموذج الشبكة	DualStreamResUNet
معدل العينة	16,000 Hz
طول مقطع التدريب	2.0 ثانية
N_FFT / HOP / WIN	512 / 128 / 512
حجم الدفعة	16
عدد الحقب المضبوط	50
المحسّن	AdamW

4.3 بيانات التقييم المتاحة ونطاقها

يستخدم كود التقييم مجموعة JacobLinCool/VoiceBank-DEMAND-16k مع split="test"، ويظهر عدد 824 عنصرًا في بيانات الاختبار. غير أن الدالة مقيّدة بـmax_eval_samples=100، وتحسب WER عند i < 30 فقط. ومرجع WER ناتج عن تفريغ Whisper base للصوت النظيف؛ ولذلك فهو مرجع آلي، وليس نسخًا بشريًا مستقلًا. لم تُنفذ عملية تقييم معتمدة على كامل مجموعة الفيديوهات التعليمية الإنجليزية–العربية، لأنه لا توجد مجموعة موثقة مكتملة لها حتى الآن.

وصف البيانات	المتاح الآن
مجال الاختبار	VoiceBank-DEMAND (فصل الصوت عن الضجيج)
إجمالي split test الظاهر	824 عينة
حد التقييم الصوتي	أول 100 عينة كحد أقصى
حد WER	أول 30 عينة كحد أقصى
المرجع النصي لـWER	تفريغ Whisper base للصوت النظيف

4.4 المعمارية المقترحة للمنظومة

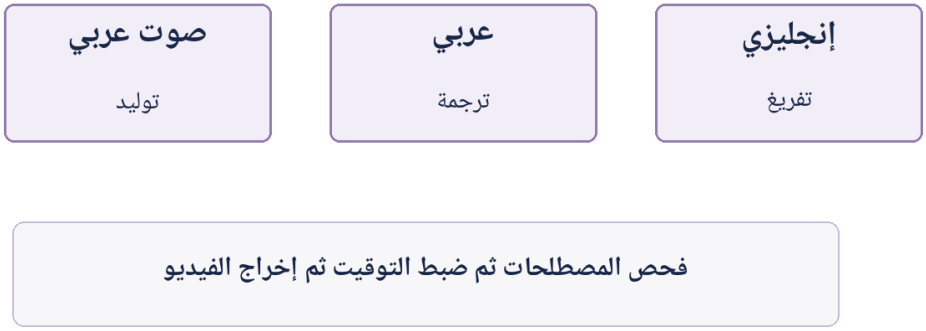


الشكل 1: تدفق مكونات الدبلجة المقترحة؛ فصل الكلام يستخدم النموذج المدرّب مسبقًا، وليس خطوة تدريب تتكرر مع الفيديو.

نستخرج الصوت من الفيديو، ثم نستخدم نموذج فصل الصوت عن الضجيج المدرَّب مسبقًا. وتتطلب الموسيقى والمؤثرات، إن وجدت، معالجة منفصلة. بعدها يُفرَّغ الكلام الإنجليزي ويُحاذى زمنيًا، وتُنجز الترجمة العربية المراعية للسياق والمصطلحات، يليها توليد الصوت وضبط المدة ومزامنة الشفاه عند ظهور وجه مناسب. أخيرًا يُمزج الصوت العربي ويُدمج مع الفيديو. فصل المتحدثين خارج النطاق الحالي.

المكوّن	العمل	حالة التنفيذ
فصل الكلام عن الضجيج	النموذج المدرَّب على الصوت	منجز وله نتائج تقييم جزئية.
استخراج الصوت	فصل صوت الفيديو عن صورته	تجربة سابقة موثقة في الدفتر.
ASR ومحاذاة الكلمات	WhisperX وطوابع الكلمات	تجارب محفوظة سابقًا.
الترجمة السياقية	قائمة مصطلحات وسياق الدرس	منهجية مقترحة للتطوير والمقارنة.
فحص الترجمة	كشف فقد المصطلحات والأرقام	مقترح للاختبار وليس ضمانًا دلاليًا.
توليد الكلام العربي	TTS عربي ونطق المصطلحات	تجارب سابقة، مع تطوير مستقبلي.
تكييف مدة الكلام	Duration Control بعد TTS	مقترح وتجارب مخططة.
الشفاه	Lip Sync فقط عند وجود وجه	لا نتائج تشغيل نهائية معتمدة.
المزج وإخراج الفيديو	FFmpeg والمكونات الصوتية	سجل تنفيذ سابق؛ فحص الجودة ناقص.

4.5 منهجية الترجمة ذات المراحل الست



الشكل 2: موقع الترجمة العربية وتوليد الكلام داخل مسار الدبلجة.

4.5.1 حزمة المقطع

حفظ معرف الوحدة الأصلي، والنص الإنجليزي، والتوقيت وأزمنة الكلمات المحاذاة، والسياق المجاور.

4.5.2 فهم السياق

استنتاج موضوع الدرس والمصطلحات المتكررة باستخدام المعلومات النصية الموثقة؛ دون ادعاء فهم بصري لم ينفذ.

4.5.3 ترجمة دقيقة أولية

إنتاج نص عربي يحافظ على المعنى العلمي والأرقام والنفي ومقابلات المصطلحات.

4.5.4 تكييف للإلقاء

إعادة صياغة عربية فصحى طبيعية وسهلة النطق مع المحافظة على المعلومات.

4.5.5 مراعاة طول الجملة

تقدير طول النطق قبل TTS ثم قياس المدة الفعلية بعد توليد الصوت وتعديل النص عند الحاجة.

4.5.6 فحص جودة آلي

مقارنة النص العربي بالأصل وفحص المصطلحات والأرقام والتوقيت؛ لا يعد حكمًا معصومًا عن الخطأ.

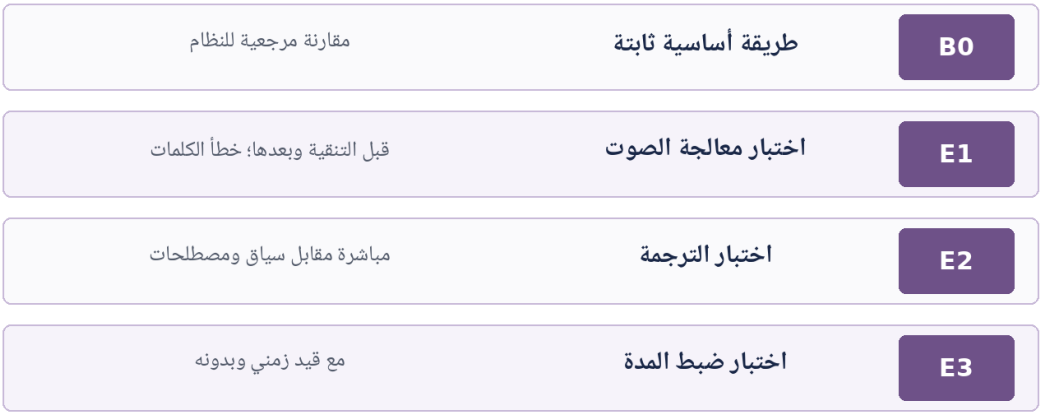
ملاحظة توثيقية — مثال تعليمي توضيحي

اختلاف ترجمة كلمة script بين «نص» و«شيفرة» مثال مقصود لشرح أثر السياق، وليس نتيجة تشغيل مقاسة من نظام الترجمة.

4.6 إعداد مجموعة بيانات مستقلة للبحث

تحتاج تجارب الترجمة والتزامن إلى مجموعة فيديوهات تعليمية إنجليزية ذات حقوق استخدام واضحة، وتوثيق مدة الفيديو والمجال واسم المحاضر عند السماح بذلك، ومحتوى الضجيج ووجود وجه قابل للشفاه. كما يلزم إنشاء تفريغ إنجليزي وترجمة عربية مرجعيين بصورة مستقلة عن مخرجات النظام، مع الاحتفاظ بعلاقة كل مقطع وتوقيته الأصليين. لم تتحدد الأعداد أو ساعات المحتوى حتى الآن.

4.7 خطة المقارنات واختبار أثر التحسينات



الشكل 3: أربع حالات مقترحة للمقارنة؛ التجارب المخططة ليست نتائج أُنجزت.

التجربة	المتغير المحدد	ما الذي نقيسه؟	الحالة
B0	خط معالجة مرجعي ثابت	جودة اللغة والصوت والتوقيت	مطلوب التثبيت.
E1	صوت خام مقابل صوت مفصول ثابت ASR عن الضجيج مع	WER وSI-SDR عند توافر مراجع مناسبة	لم يُختبر على الفيديوهات التعليمية بعد.
E2	ترجمة مباشرة مقابل ترجمة بالسياق والمصطلحات	chrF++/COMET ودقة مصطلحات	مخططة.
E3	ترجمة بلا قيد طول مقابل ترجمة مضبوطة المدة	Duration Error مع جودة المعنى	مخططة.
Ablation	إزالة مكون واحد أو إضافته تحت نفس الإعدادات	أثر كل خطوة على النتائج النهائية	مخططة.

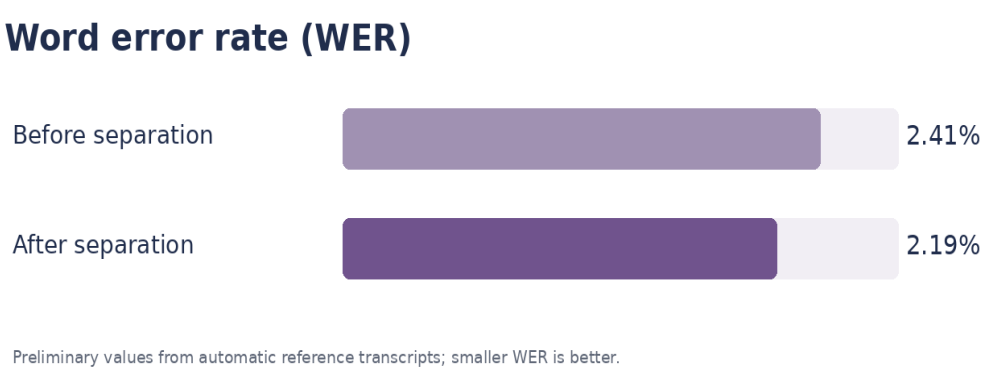
تُثبّت نماذج بقية المراحل وإصداراتها والبذور العشوائية ومعرفات التشغيل. ويجب تقسيم مجموعة البيانات على مستوى الفيديو والمحاضر قدر الإمكان لمنع انتقال مقاطع شبه متطابقة بين التطوير والاختبار. بعد الحساب تُقدّم المتوسطات والتوزيع وفترات الثقة، وتُفسّر النتائج السلبية أيضًا بصورة علمية.

الفصل الخامس — النتائج المتاحة ومناقشتها

5.1 نتائج نموذج فصل الصوت عن الضجيج

الجدول التالي يعرض القيم الظاهرة في لقطة مخرجات التقييم المحفوظة، دون تعديل أو إعادة حساب. يجب قراءتها في حدود البيانات الموصوفة في الفصل الرابع، لا بوصفها نتيجة الدبلجة التعليمية من البداية إلى النهاية.

المقياس	القيمة المسجلة	دلالته	نطاقه وحدوده
PESQ	2.6918	الجودة الإدراكية للكلام بعد فصل الضجيج	حتى 100 تسجيل من مجموعة الاختبار.
STOI	0.9385	قابلية فهم الكلام	حتى 100 تسجيل.
DNSMOS	3.0857	تقدير جودة بلا مرجع نظيف	حتى 100 تسجيل، وفق نجاح حساب المقياس.
SI-SDR	20.2707 dB	جودة الفصل بالنسبة لمرجع نظيف	لا يُعاد تسميته SI-SDRi.
WER_NOISY	0.0241 (2.41%)	خطأ تفريغ الكلام المشوش	أول 30 عينة بمرجع Whisper آلي.
WER	0.0219 (2.19%)	خطأ تفريغ الكلام المفصول عن الضجيج	أول 30 عينة بمرجع Whisper آلي.



الشكل 4: مقارنة متوسطي WER المسجلين من لقطة التقييم؛ لا يعني الفرق دلالة إحصائية مؤكدة.

5.2 قراءة الفرق بين WER قبل المعالجة وبعدها

انخفض متوسط WER المسجل من 2.41% إلى 2.19%، بفارق 0.22 نقطة مئوية، أي نحو 9.1% انخفاض نسبي إذا استُخدم المتوسطان المعروضان. لا يجوز عدّ الفرق دليلًا قاطعًا على تحسن عام؛ فالعينة صغيرة ومرجع التفريغ آلي، ولا تتوفر لدينا فترات ثقة أو اختبار دلالة إحصائية أو توزيع النتائج بحسب المتحدث ونوع الضجيج.

5.3 ما الذي أثبتته التجارب وما الذي لم تثبته؟

أُنجز تدريب نموذج فصل الصوت عن الضجيج وتقييمه وتوثيق نتائجه الصوتية المحددة. أما جودة ترجمة EN→AR والمحافظة على مصطلحات المحاضرات ونطق الصوت العربي وتوقيت الفيديو ومزامنة الشفاه فلم تُقَس بعد على مجموعة تعليمية مرجعية كاملة. لذلك نفصل نتائج هذا المكوّن عن التقييم الشامل للدبلجة.

5.4 محدوديات النتائج الحالية

- تقييم المقاييس الصوتية مقتصر على حد أقصى يبلغ 100 من أصل 824 عنصر اختبار.

- تقييم WER مقتصر على أول 30 عينة ويستخدم مرجع تفريغ آلي من Whisper base على الصوت النظيف.
- لا توجد مقارنة موحدة مع نماذج فصل كلام أخرى بالإعدادات والبيانات نفسها.
- لا توجد نتائج موثقة لمقاييس الترجمة العربية أو توافق مدة TTS أو جودة فيديوهات الدبلجة التعليمية.

5.5 مناقشة أولية

تمثل القيم المعروضة مؤشرًا على أن منظومة التدريب الصوتي قابلة للتشغيل والتقييم. وتفيد هذه النتائج في بناء خطة تجارب E1 حين تتوفر بيانات تعليمية مستقلة، لكنها لا تخبرنا بعد إذا كان انخفاض الضجيج يحسن ترجمة المصطلحات، أو إذا كان ضبط طول العربية يؤدي إلى تزامن أفضل من دون فقد المعنى. ولا يجوز ترتيب نموذجنا أمام دراسات أخرى تعتمد مجموعات اختبار أو بروتوكولات مختلفة، حتى لو كانت مقاييسها تحمل الأسماء نفسها.

الفصل السادس — الاستنتاجات والعمل المستقبلي

6.1 ما تحقق حتى الآن

أُنجز تدريب نموذج لفصل الصوت عن الضجيج، وسُجلت له نتائج تقييم صوتية أولية. كما نُفذت بعض مراحل نظام الدبلجة برمجيًا: استخراج الصوت والتفريغ والترجمة وتوليد الكلام والمزج. وفرت هذه الأعمال أساسًا هندسيًا للبحث، لكن المنظومة النهائية لم تخضع بعد لبروتوكول اختبار مستقل يقيس جودة الفيديو المدبلج من بدايته إلى نهايته.

6.2 توصيات استكمال الدراسة

- تحديد هوية الأوزان التدريبية وحفظ SHA256 ومعلومات البيانات والبرمجيات والإعدادات قبل إعادة القياس.
- إعداد بيانات فيديو تعليمية مرخصة ومراجع عربية وإنجليزية مستقلة، مع تحديد حجم العينة وخطة التقسيم.
- تقييم أثر فصل الصوت عن الضجيج على دقة تفريغ الكلام في المجال التعليمي الجديد، مع WER بمرجع بشري أو معتمد مستقل.
- اختبار ترجمة سياقية مدعومة بقائمة مصطلحات ومقارنتها بطريقة أساسية ثابتة.
- توليد صوت عربي وضبط مدته وقياس الطبيعية والنطق والتزامن بصورة مستقلة.
- اختبار مزامنة الشفاه في المقاطع المناسبة فقط، وتوثيق الجودة المرئية والحقوق.

6.3 المخاطر وخيارات التخفيف

المخاطرة	التأثير	إجراء مقترح
ضعف تمثيل المجال التعليمي في البيانات	تدهور الترجمة أو ASR	تقسيم واضح، عينات مستقلة، تحليل مفردات ومجالات.
خطأ علمي بسبب اختصار الترجمة	فقد معنى أو معلومة	مراجعة مصطلحات وأرقام ونفي ومراجع ترجمة مستقلة.
اختلاف مدة النطق	تقدم أو تأخر الكلام العربي	قياس مدة TTS فعليًا وإعادة الصياغة وفق نافذة زمنية.
نطق عربي غير طبيعي	انخفاض فهم المتعلم	تهيئة النص والتشكيل وفحص لفظ المصطلحات.
تراخيص مقيّدة	تعذر التسويق	اختيار نماذج وبيانات مرخصة أو استصدار حقوق مناسبة.
غياب مراجع مستقلّة	نتائج غير قابلة للدفاع	إعداد مجموعة ذهبية وبروتوكول معتمد قبل التجربة النهائية.

6.4 الخاتمة

إن دبلجة المحتوى التعليمي إلى العربية مهمة متعددة المراحل تتطلب فصل الصوت عن الضجيج، وترجمة دقيقة، وكلامًا عربيًا مناسبًا للإلقاء، وتزامنًا مع الفيديو. يضم المشروع نموذجًا مدرّبًا لفصل الصوت عن الضجيج ونتائج تقييم موثقة لهذا المكوّن، مع خطة لاستكمال التكامل والتحقق من أداء المنظومة على بيانات تعليمية مستقلة. وستُقاس مساهمة كل مرحلة من خلال مقارنات واضحة دون تعميم نتائج مكوّن واحد على النظام كله.

المراجع

[R1] Brannon et al. (2023). Dubbing in Practice: A Large Scale Study of Human Localization With Insights for Automatic Dubbing. TACL.
https://aclanthology.org/2023.tacl-1.25/

[R2] Wu et al. (2025). Locate-and-Focus: Enhancing Terminology Translation in Speech Language Models. ACL.
https://aclanthology.org/2025.acl-long.556/

[R3] Won et al. (2025). End-to-End Multilingual Automatic Dubbing via Duration-based Translation with Large Language Models. EMNLP.
https://aclanthology.org/2025.emnlp-demos.37/

[R4] Bain et al. (2023). WhisperX: Time-Accurate Speech Transcription of Long-Form Audio.
https://arxiv.org/abs/2303.00747

[R5] Sibaee et al. (2026). ASCAT: Arabic Scientific Benchmark for Advanced Translation Evaluation. OSACT.
https://aclanthology.org/2026.osact-1.9/

[R6] Alshammari et al. (2026). Quanta: A Fine-Grained Dataset and Benchmark for Arabic Machine-Translation Error Analysis. ArabicNLP.
https://aclanthology.org/2026.arabicnlp-main.32/

[R7] Lodagala et al. (2025). SawtArabi: A Benchmark Corpus for Arabic TTS. Interspeech.
https://www.isca-archive.org/interspeech_2025/lodagala25_interspeech.html

[R8] Rei et al. (2020). COMET: A Neural Framework for MT Evaluation. EMNLP.
https://aclanthology.org/2020.emnlp-main.213/

[R9] Choi et al. (2026). X-Dubbing: Speech-to-Speech Translation under Temporal and Visual Constraints. arXiv preprint.
https://arxiv.org/abs/2610.32042

[R10] Le Roux et al. (2019). SDR — Half-Baked or Well Done? ICASSP.
https://research.google/pubs/sdr-half-baked-or-well-done/

[R11] Meta. Arabic MMS TTS model card and license.
https://huggingface.co/facebook/mms-tts-ara

[R12] Wav2Lip official repository and usage restrictions.
https://github.com/Rudrabha/Wav2Lip